LAB2 part2 Оброблення даних про файли (робочий зошит)

Exported 01.03.2026, 23:04:16

LAB2 Частина 2. Оброблення даних про файли

Виконавець: Шевченко Микола Вікторович, група К-27
Викладач: Ляшко Андрій

Нам знадобиться бібліотека `pandas`.
Бібліотека є сторонньою, отже потребує встановлення. Краще у віртуальне оточення. Мала бути встановлена, якщо ні (клітина з імпортуванням виконується з помилкою), то треба встановити. Можна прямо з Jupyter. Тільки не під час пари.

Наступну клітину можна розкоментовувати та виконувати тільки, якщо в якості ядра (kernel) вибране віртуальне оточення!

In [79]:

```
#!pip install pandas
```

Якщо встановлювати не в оточення, то хоча б тільки для користувача (з ключем --user).

In [80]:

```
#!pip3.14 install pandas --user    # Linux
```

In [81]:

```
#!py -3.14 -m pip install pandas --user    # Windows
```

In [82]:

```
from pathlib import Path
import pandas as pd
print(f'pandas {pd.__version__}')
```

```
pandas 3.0.0
```

The document was converted with **Code-Format**: https://code-format.com/

Постановка задачі

Згадка про минуле (Лабораторну роботу №1)
Протягом навчання програмні проєкти з різних предметів зберігалися в папках з переліку `folders`, який оброблявся в лабораторній роботі №1.
Щоб профільтрувати допоміжні файли середовищ, було введено "білий список" розширень (`WHITE_LIST`) та список розширень файлів з текстом програм(задається) (`CODE_LIST`).
Також було написано функцію `kind`, що за розширенням повертає рядок з символом C,W або O відповідно для файлів з текстом програм (відповідно до переліку `CODE_LIST`), інших з білого списку, та тих, що не потрапили в білий список).

У результаті виконання лабораторної роботи для кожного місяця та кожного розширення, що зустрічаються при перегляді файлів, розміщених у папках зі списку, було знайдено таку інформацію:

`рік, місяць, розширення, кількість файлів, сумарний обсяг у байтах, кількість їх рядків.`

Кількість рядків наводиться тільки для розширень категорії C; білі та порожні рядки не рахуються; для інших розширень ця клітина таблиці залишається незаповненою.

За цією інформацією було побудовано csv-файл з іменем `lab1_1.csv` (кодування тільки utf-8), на початку якого розміщено рядок з заголовками: year, mon, ext, cnt, size, lines.

In [83]:

```
CODE_LIST = {'.cpp', '.hpp', '.c', '.h', '.py', '.pyw', '.cs', '.js',
'.java'}
WHITE_LIST = CODE_LIST | {'.html', '.json', '.txt', '.ipynb'}
```

In [84]:

```
headers = ['year', 'mon', 'ext', 'cnt', 'size', 'lines']
```

The document was converted with **Code-Format**: https://code-format.com/

За інформацією з csv-файлу з'ясувати

1. Скільки різних розширень зустрічається у папках з заданого списку, скільки файлів з кожним розширенням. (Для цієї задачі розглядаємо всі розширення, а не тільки "білого списку".)
   Відповідну інформацію вивести на екран у табличному вигляді. Рядки таблиці містять розширення, кількість файлів та ознаку (C,W,O відповідно для файлів з текстом програм (розширення з списку `CODE_LIST`), інших з білого списку, та тих, що не потрапили в білий список). Інформація подається за спаданням кількості файлів.
2. За датами створення файлів для кожного місяця, починаючи з вересня 2024-го року, знайти таку інформацію: кількість файлів з розширеннями з "білого списку", їх сумарний розмір у кілобайтах, кількість їх рядків (враховувати тільки для файлів категорії C), середній розмір у байтах, середню кількість рядків.
   Відповідну інформацію вивести на екран у табличному вигляді в порядку, оберненому до хронологічного.

Зверніть увагу на підписи стовпчиків, що будуть виводитись.

Всі значення округлити та привести до цілого типу.

Завантаження даних

Задаємо шлях до файлу `lab1_1.csv`.

In [85]:

```
path = Path("lab1_1.csv")
```

Завантажимо дані за допомогою функції `pd.read_csv` (документація тут).

Зверніть увагу на те, що:

1. файл записано в кодуванні `utf-8`
2. перший рядок файлу містить заголовки year, mon, ext, cnt, size, lines
3. значення у стовпчику lines можуть бути відсутні

▶ Підказки.

▶ Ще більше підказок

The document was converted with **Code-Format**: https://code-format.com/

In [86]:

```
data = pd.read_csv(path, encoding = 'utf-8', header=0, sep=",", dtype=
{"lines": "Int64"}, names=headers, usecols=headers)
data.head(3)
```

	year	mon	ext	cnt	size	lines
0	2025	1	.cpp	1	929	33
1	2025	1	.h	2	2090	103
2	2025	1	.json	2	5086	<NA>

In [87]:

```
data.tail(3)
```

	year	mon	ext	cnt	size	lines
27	2025	12	.cs	7	6512	217
28	2025	12	.json	4	15008	<NA>
29	2025	12	.txt	1	414	<NA>

Подивимось інформацію про завантажені дані. Документація на метод `info`.

The document was converted with **Code-Format**: https://code-format.com/

In [88]:

```
data.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 30 entries, 0 to 29
Data columns (total 6 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   year    30 non-null     int64
 1   mon     30 non-null     int64
 2   ext     30 non-null     str
 3   cnt     30 non-null     int64
 4   size    30 non-null     int64
 5   lines   18 non-null     Int64
dtypes: Int64(1), int64(4), str(1)
memory usage: 1.6 KB
```

Бачимо, що відсутні значення є не тільки в стовпчику `lines`, що природньо, бо кількість рядків обчислювалась не для всіх розширень, але і в стовпчику `ext` з розширеннями.

Замінимо відсутні розширення порожнім рядком.

Використаємо метод `fillna`.

Слід замінити тільки відсутні розширення, тому значення параметра `value` слід зробити словником, що для кожного стовпчика, який слід оброблювати, задає значення-заповнювач.
Не забудьте, що перетворення слід виконувати "на місці".

▶ Підказка (тільки за повного безвихіддя)

Альтернатива. Можна спробувати перетворити тільки стовпчик `data.ext`.
▶ Підказка (тільки за повного безвихіддя)

Перший спосіб більш економний за пам'яттю. Другий спосіб корисний тоді, коли для різних стовпчиків використовують різні алгоритми заповнення відсутніх значень.

The document was converted with **Code-Format**: https://code-format.com/

In [89]:

```
data.fillna(value={'ext': ''}, inplace=True)
data.head(3)
```

	year	mon	ext	cnt	size	lines
0	2025	1	.cpp	1	929	33
1	2025	1	.h	2	2090	103
2	2025	1	.json	2	5086	<NA>

In [90]:

```
data.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 30 entries, 0 to 29
Data columns (total 6 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   year    30 non-null     int64
 1   mon     30 non-null     int64
 2   ext     30 non-null     str
 3   cnt     30 non-null     int64
 4   size    30 non-null     int64
 5   lines   18 non-null     Int64
dtypes: Int64(1), int64(4), str(1)
memory usage: 1.6 KB
```

Тепер незаповнені дані залишились тільки у стовпчику `lines`.

`Ні в якому разі там не повинно бути нулів!`

Групування та групові операції

The document was converted with **Code-Format**: https://code-format.com/

In [91]:

```
data.head()
```

	year	mon	ext	cnt	size	lines
0	2025	1	.cpp	1	929	33
1	2025	1	.h	2	2090	103
2	2025	1	.json	2	5086	<NA>
3	2025	2	.cpp	7	5860	202
4	2025	2	.h	4	1619	66

Задача 1 Скільки різних розширень зустрічається в папках з заданого списку, скільки файлів з кожним розширенням?

Відповідну інформацію вивести на екран у табличному вигляді. Рядки таблиці містять розширення, кількість файлів та ознаку (C,W,O відповідно для файлів з текстом програм (розширення з списку `CODE_LIST`), інших з білого списку, та тих, що не потрапили в білий список). Інформація подається за спаданням кількості файлів.

Скільки різних розширень зустрічається в папках з заданого списку?

Найпростіше: взяти стовпчик таблиці, що зберігає розширення, та знайти кількість унікальних значень.

▶ Підказки

In [92]:

```
data.ext.nunique()
```

```
6
```

Скільки файлів з кожним розширенням?

Відповідну інформацію вивести на екран у табличному вигляді. Рядки таблиці містять розширення, кількість файлів та ознаку (C,W,O відповідно для файлів з текстом програм (розширення з списку `CODE_LIST`), інших з білого списку, та тих, що не потрапили в білий список). Інформація подається за спаданням кількості файлів.

The document was converted with **Code-Format**: https://code-format.com/

Спочатку треба підсумувати інформацію по кожному розширенню. Допоможе метод `groupby` [документація тут](#).

Групувати слід за розширенням (параметр `by`) і для кожної групи обчислити суму кількостей файлів (метод `sum`).

Щоб не сумувати роки, місяці тощо, групування слід застосувати до вибірки потрібних стовпчиків. Маємо вибрати стовпчик, за яким групуємо, і стовпчик, який сумуємо.

▶ Підказка

Результат присвоїти змінній `task1`.

In [93]:

```
task1  = data[["ext", "cnt"]].groupby(by=["ext"]).sum()
task1
```

	cnt
ext	
.cpp	42
.cs	65
.h	19
.java	497
.json	83
.txt	173

Відсортувати за спаданням кількості файлів. Допоможе метод `sort_values` ([документація тут](#)).

Не забудьте вказати, що сортування відбувається за спаданням та "на місці".

▶ Підказки

The document was converted with **Code-Format**: https://code-format.com/

In [94]:

```
task1.sort_values(by='cnt', ascending=False, inplace=True)
task1.head(3)
```

	cnt
ext	
.java	497
.txt	173
.json	83

За умовою ще треба додати стовпчик з ознакою категорії розширення файлу W,C,O (див. умову). У лабораторній роботі №1 була написана функція `kind`, що за розширенням повертає рядок з шуканою ознакою. Використаємо її.

In [95]:

```
def kind(extension):   # записати
    if extension in CODE_LIST:
        return 'C'
    elif extension in WHITE_LIST:
        return 'W'
    else:
        return 'O'
```

Додамо до таблиці стовпчик з ознаками розширень файлів.

Зараз розширення є індексом. За допомогою методу метод `reset_index` ([документація тут](#)) зробимо його стовпчиком таблиці.

Не забувайте виконувати перетворення "на місці".

The document was converted with **Code-Format**: https://code-format.com/

In [96]:

```
task1.reset_index(inplace=True)
task1.head(3)
```

	ext	cnt
0	.java	497
1	.txt	173
2	.json	83

Тепер вже додаємо стовпчик з ознаками.

▶ Підказки

In [97]:

```
task1['kind'] = task1.ext.apply(kind)
task1.head(3)
```

	ext	cnt	kind
0	.java	497	C
1	.txt	173	W
2	.json	83	W

За допомогою методу `set_index` ([документація тут]) знов зробимо розширення індексом таблиці.

Тут: Значенням параметра `keys` має стати ім'я стовпчика, що слід використати як індекс.

Не забувайте виконувати перетворення "на місці".

The document was converted with **Code-Format**: https://code-format.com/

In [98]:

```
task1.set_index(keys='ext', inplace=True)
task1.head(3)
```

	cnt	kind
ext		
.java	497	C
.txt	173	W
.json	83	W

Змінимо написи.

In [99]:

```
task1.index.name='Розширення'
task1.columns=['Кількість файлів','Ознака']
task1.head()
```

	Кількість файлів	Ознака
Розширення		
.java	497	C
.txt	173	W
.json	83	W
.cs	65	C
.cpp	42	C

The document was converted with **Code-Format**: https://code-format.com/

In [100]:

```
task1.head(20)
```

	Кількість файлів	Ознака
Розширення		
.java	497	C
.txt	173	W
.json	83	W
.cs	65	C
.cpp	42	C
.h	19	C

Задача 2 За датами створення файлів для кожного місяця знайти таку інформацію: кількість файлів з розширеннями з "білого списку", їх сумарний розмір у кілобайтах, кількість їх рядків (враховувати тільки для файлів категорії C), середній розмір у байтах, середню кількість рядків.

Відповідну інформацію вивести на екран у табличному вигляді в порядку, оберненому до хронологічного.

Всі значення округлити та привести до цілого типу.

План:

1. Додати до початкової таблиці `data` стовпчик `kind`, що містить ознаки розширень.
2. Вибрати дані, що стосуються розширень з "білого списку".
3. Згрупувати вибрані дані в межах року та місяця.
4. За згрупованою інформацією обчислити потрібні агрегати.
5. Виконати перетворення стовпчиків та відсортувати.

Щоб за невдачі повторно не завантажувати дані, створимо їх копію.

In [101]:

```
data1 = data.copy()
```

1. Додати до початкової таблиці `data` стовпчик `kind`, що містить ознаки розширень.

Аналогічно тому, що виконувалось раніше, додати до таблиці `data1` стовпчик `kind`, що містить ознаки.

The document was converted with **Code-Format**: https://code-format.com/

In [102]:

```
data1['kind'] = data1.ext.apply(kind)
data1.head(3)
```

	year	mon	ext	cnt	size	lines	kind
0	2025	1	.cpp	1	929	33	C
1	2025	1	.h	2	2090	103	C
2	2025	1	.json	2	5086	<NA>	W

2. Вибрати дані, що стосуються розширень з "білого списку".

Запишіть вираз, що задає вибірку тільки інформації про розширення з "білого списку". Щоб далі не копіювати сам вираз, присвойте його значення змінній `selection`. (Це є зручно, коли експериментуємо, у продакшн потреби в цій змінній насправді не буде, замість неї можна буде використовувати вираз безпосередньо.)

▶ Підказка

In [103]:

```
selection = data1[data1.kind != 'O']
selection.head()
```

	year	mon	ext	cnt	size	lines	kind
0	2025	1	.cpp	1	929	33	C
1	2025	1	.h	2	2090	103	C
2	2025	1	.json	2	5086	<NA>	W
3	2025	2	.cpp	7	5860	202	C
4	2025	2	.h	4	1619	66	C

3. Згрупувати вибрані дані за ознаками в межах року та місяця.

   Допоможе метод `groupby` [документація тут](#).

Групувати слід за роком та місяцем (параметр `by` має бути списком). Оскільки далі будемо обчислювати статистики для розміру та кількості рядків, то перед групуванням з таблиці слід вибрати стовпчики, за якими групуємо і за якими обчислюємо статистики.

The document was converted with **Code-Format**: https://code-format.com/

In [104]:

```
task2 = selection[['year', 'mon', 'cnt', 'size', 'lines']].groupby(by=
['year', 'mon'])
```

Далі необхідно знайти кількість файлів за кожен місяць, їх сумарний та середній розмір, а також сумарну та середню кількість рядків.

У результаті групування отримався об'єкт `DataFrameGroupBy` (документація тут).

До нього застосовний метод `agg`, що обчислює статистики (агрегатні характеристики) (документація тут).

Для стовпчика `cnt` будемо шукати суму значень (`sum`), для стовпчика `size` будемо шукати суму значень та середнє значення (`mean`), для стовпчика `lines` будемо шукати суму значень та середнє значення.

Першим параметром методу `agg` зробимо словник, що задає які статистики для яких стовпчиків слід обчислювати. Ключами словника мають бути імена стовпчиків (рядки), а значеннями списки статистик або окремі статистики (статистики також задаємо рядками-іменами)).

Результат агрегування зробимо значенням змінної `res2`.

In [105]:

```
res2 = task2.agg({'cnt': 'sum', 'size': ['sum', 'mean'], 'lines':
['sum', 'mean']})
res2.head()
```

		cnt	size		lines	
		sum	sum	mean	sum	mean
year	**mon**					
2025	**1**	5	8105	2701.666667	136	68.0
	2	17	33143	11047.666667	268	134.0
	3	9	19654	6551.333333	254	127.0
	4	22	44792	14930.666667	617	308.5
	5	40	2669636	667409.000000	1500	750.0

The document was converted with **Code-Format**: https://code-format.com/

Оскільки відбувалось групування по кільком стовпчикам та для окремих стовпчиків обчислювалось кілька характеристик, то отримали складені індекси (multindex) і рядків, і стовпчиків.

Поточний індекс стовпчиків.

In [106]:

```
res2.columns
```

```
MultiIndex([(  'cnt',  'sum'),
            ( 'size',  'sum'),
            ( 'size', 'mean'),
            ('lines',  'sum'),
            ('lines', 'mean')],
           )
```

Перейдемо до простого індексу стовпчиків.

In [107]:

```
res2.columns = res2.columns.to_flat_index()
res2.columns
```

```
Index([   ('cnt', 'sum'),   ('size', 'sum'),  ('size', 'mean'),
        ('lines', 'sum'), ('lines', 'mean')],
      dtype='object')
```

In [108]:

```
res2.head(3)
```

		(cnt, sum)	(size, sum)	(size, mean)	(lines, sum)	(lines, mean)
year	**mon**					
2025	**1**	5	8105	2701.666667	136	68.0
	2	17	33143	11047.666667	268	134.0
	3	9	19654	6551.333333	254	127.0

The document was converted with **Code-Format**: https://code-format.com/

Змінимо назви стовпчиків.

In [109]:
```
res2.columns=['Кількість', 'Сумарний розмір', 'Середній розмір',
'Кількість рядків', 'Середня кількість рядків',]
res2.head(3)
```

		Кількість	Сумарний розмір	Середній розмір	Кількість рядків	Середня кількість рядків
year	**mon**					
2025	**1**	5	8105	2701.666667	136	68.0
	2	17	33143	11047.666667	268	134.0
	3	9	19654	6551.333333	254	127.0

Виразимо сумарний розмір у kb.

Для цього слід поділити значення на 1024, округлити. Додатково перетворимо на цілий тип (метод `astype` дозволяє виконувати перетворення типів, [документація тут](#)). Також не забудемо змінити підпис стовпчика.

Переходимо до кілобайтів.

In [110]:
```
res2['Сумарний розмір'] = (res2['Сумарний розмір'] /
1024).round().astype(int)
```

Змінюємо підпис стовпчиків

In [111]:
```
res2.columns = ['Кількість', 'Сумарний розмір, kb', 'Середній розмір,
b', 'Кількість рядків', 'Середня кількість рядків',]
```

The document was converted with **Code-Format**: https://code-format.com/

In [112]:

```
res2.head(3)
```

		Кількість	Сумарний розмір, kb	Середній розмір, b	Кількість рядків	Середня кількість рядків
year	**mon**					
2025	**1**	5	8	2701.666667	136	68.0
	2	17	32	11047.666667	268	134.0
	3	9	19	6551.333333	254	127.0

Округлити середній розмір та середню кількість рядків, перейти до цілих значень.

In [113]:

```
res2.info()
```

```
<class 'pandas.DataFrame'>
MultiIndex: 9 entries, (np.int64(2025), np.int64(1)) to
(np.int64(2025), np.int64(12))
Data columns (total 5 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   Кількість                 9 non-null      int64
 1   Сумарний розмір, kb       9 non-null      int64
 2   Середній розмір, b        9 non-null      float64
 3   Кількість рядків          9 non-null      Int64
 4   Середня кількість рядків  9 non-null      Float64
dtypes: Float64(1), Int64(1), float64(1), int64(2)
memory usage: 565.0 bytes
```

Ось тільки тепер замінимо відсутні значення кількості рядків нулями!

Якщо б це було зроблено раніше, то середня кількість рядків була б обрахована неправильно (на неї вплинули б нульові значення замість відсутніх).

▶ Підказка

The document was converted with **Code-Format**: https://code-format.com/

In [114]:

```
res2.fillna(0, inplace=True)
res2.info()
```

```
<class 'pandas.DataFrame'>
MultiIndex: 9 entries, (np.int64(2025), np.int64(1)) to
(np.int64(2025), np.int64(12))
Data columns (total 5 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   Кількість                 9 non-null      int64
 1   Сумарний розмір, kb       9 non-null      int64
 2   Середній розмір, b        9 non-null      float64
 3   Кількість рядків          9 non-null      Int64
 4   Середня кількість рядків  9 non-null      Float64
dtypes: Float64(1), Int64(1), float64(1), int64(2)
memory usage: 565.0 bytes
```

Тепер можна перетворювати типи стовпчиків.

In [115]:

```
fname = 'Середній розмір, b'
res2[fname] = res2[fname].round().astype(int)

fname = 'Середня кількість рядків'
res2[fname] = res2[fname].round().astype(int)
```

The document was converted with **Code-Format**: https://code-format.com/

In [116]:

```
res2
```

		Кількість	Сумарний розмір, kb	Середній розмір, b	Кількість рядків	Середня кількість рядків
year	**mon**					
2025	**1**	5	8	2702	136	68
	2	17	32	11048	268	134
	3	9	19	6551	254	127
	4	22	44	14931	617	308
	5	40	2607	667409	1500	750
	9	3	5	2628	85	85
	10	15	35	11838	430	215
	11	756	8702	1485190	96526	24132
	12	12	21	7311	217	217

Відсортуємо в порядку, оберненому до хронологічного.

У даному випадку слід сортувати індекс. Допоможе метод `sort_index` (документація тут).

The document was converted with **Code-Format**: https://code-format.com/

In [117]:

```
res2.sort_index(ascending=[False, False], inplace=True)
res2
```

		Кількість	Сумарний розмір, kb	Середній розмір, b	Кількість рядків	Середня кількість рядків
year	**mon**					
2025	**12**	12	21	7311	217	217
	11	756	8702	1485190	96526	24132
	10	15	35	11838	430	215
	9	3	5	2628	85	85
	5	40	2607	667409	1500	750
	4	22	44	14931	617	308
	3	9	19	6551	254	127
	2	17	32	11048	268	134
	1	5	8	2702	136	68

Частину 2 зроблено!

The document was converted with **Code-Format**: https://code-format.com/